Họ và tên: Đoàn Anh Quân

MSSV: 23110111

BÀI THỰC HÀNH DATA MINING TUẦN 6

Cài đặt và thực thi code thuật toán K-medians:

- Import các thư viện và load dữ liệu:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from matplotlib.colors import ListedColormap

df = pd.read_csv(r"D:\data_mining\tuan6\data.csv")
df.head()
colnames = list(df.columns[1:-1])
```

✓ 0.0s

- Plot các dữ liệu để dễ nhìn, có phân màu lại:

```
customcmap = ListedColormap(["crimson", "mediumblue", "darkmagenta"])
fig, ax = plt.subplots(figsize=(8, 6))
plt.scatter(x=df['x'], y=df['y'], s=150,
            c=df['cluster'].astype('category'),
            cmap= customcmap)

ax.set_xlabel('x', fontsize=14)
ax.set_ylabel('y', fontsize=14)
plt.xticks(fontsize=12)
plt.yticks(fontsize=12)
plt.show()
```

✓ 0.0s

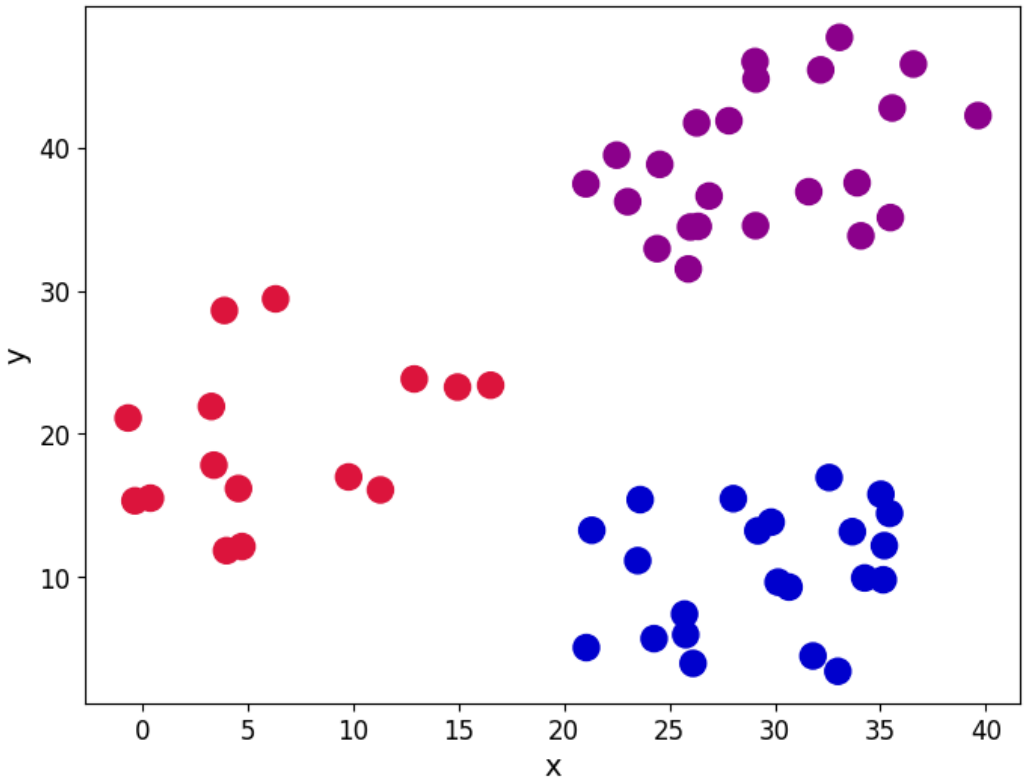

- Tạo hàm chọn ngẫu nhiên k điểm trung tâm (k = 3) và in ra xem thử:

```
def random_centroids(k, dset):
    centroids = dset.sample(k)
    return centroids

np.random.seed(42)
k = 3
centroids = random_centroids(k, df[['x', 'y']])
centroids
```

✓ 0.0s

	x	y
0	24.412	32.932
5	25.893	31.515
36	26.878	36.609

- Tạo hàm tính khoảng cách:

```
def Dist(a, b):
    return np.sum(abs(a - b))
```
✓ 0.0s

- Thử hàm tính khoảng cách với điểm thứ 36:

```
for i, centroid in enumerate(range(centroids.shape[0])):
    err = Dist(centroids.iloc[centroid, :], df.iloc[36, :])
    print('Error for centroid {0}: {1:.2f}'.format(i, err))
```
✓ 0.0s

```
Error for centroid 0: 6.14
Error for centroid 1: 6.08
Error for centroid 2: 0.00
```

- Tạo hàm tìm điểm trung tâm gần nhất với mỗi điểm dựa trên khoảng cách:

```
def centroid_assignation(dset, centroids):
    k = centroids.shape[0]
    n = dset.shape[0]
    assignation = []
    assign_errors = []
    for obs in range(n):

        all_errors = np.array([])
        for centroid in range(k):
            err = Dist(centroids.iloc[centroid, :], dset.iloc[obs, :])
            all_errors = np.append(all_errors, err)
        nearest_centroid = np.where(all_errors==np.amin(all_errors))[0].tolist()[0]
        nearest_centroid_error = np.amin(all_errors)
        assignation.append(nearest_centroid)
        assign_errors.append(nearest_centroid_error)
    return assignation, assign_errors
```
✓ 0.0s

- Thêm vào df 1 cột centroid tượng trưng cho điểm trung tâm mà điểm này chọn, 1 cột error để tính khoảng cách giữa điểm đó và điểm trung tâm. Sau đó in ra xem df:

```
df['centroid'], df['error'] = centroid_assignation(df, centroids)
df.head()
```

✓ 0.0s

	ID	x	y	cluster	centroid	error
0	0	24.412	32.932	2	0	0.000
1	1	35.190	12.189	1	1	28.623
2	2	26.288	41.718	2	2	5.699
3	3	0.376	15.506	0	0	41.462
4	4	26.116	3.963	1	1	27.775

- In ra đồ thị với các điểm trung tâm:

```
fig, ax = plt.subplots(figsize=(8, 6))
plt.scatter(x=df['x'], y=df['y'],
            c=df['cluster'].astype('category'),
            cmap= customcmap, s=80, alpha=0.5)

plt.scatter(centroids.iloc[:, 0], centroids.iloc[:, 1],
            marker= 's', s=200, c=[0, 1, 2],
            cmap= customcmap)

ax.set_xlabel('x', fontsize=14)
ax.set_ylabel('y', fontsize=14)
plt.xticks(fontsize=12)
plt.yticks(fontsize=12)
plt.show()
```

✓ 0.0s

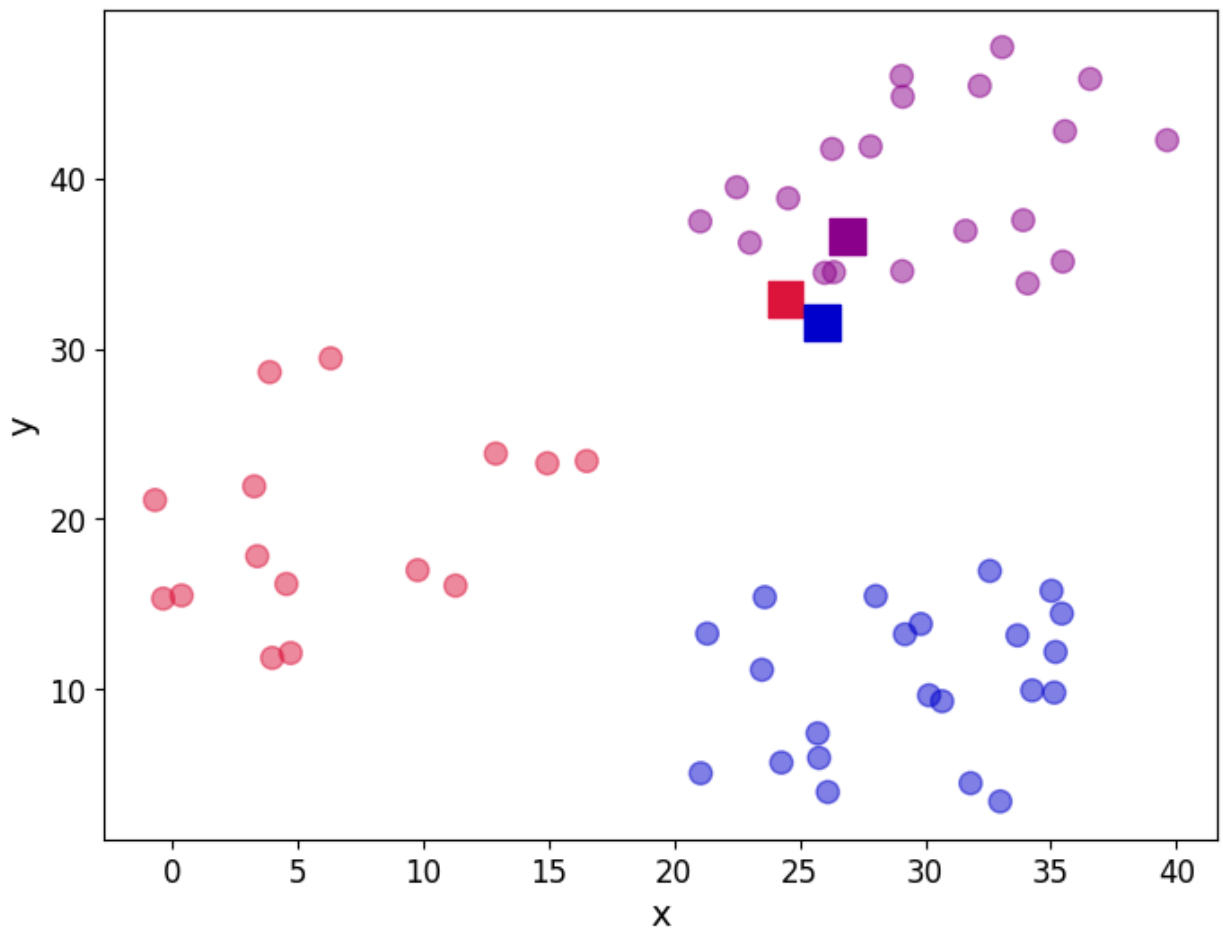

- In ra tổng error toàn bộ điểm:

```
print("The total error is {0:.2f}".format(df['error'].sum()))
✓ 0.0s

The total error is 1226.24
```

- Thay đổi các điểm trung tâm dựa trên trung vị:

```
centroids = df.groupby('centroid').agg('median').loc[:, colnames].reset_index(drop = True)
centroids
✓ 0.0s
```

	x	y
0	9.776	16.179
1	30.671	12.189
2	29.091	39.144

- In đồ thị sau khi thay đổi các điểm trung tâm:

```python
fig, ax = plt.subplots(figsize=(8, 6))
plt.scatter(x=df['x'], y=df['y'],
            c=df['cluster'].astype('category'),
            cmap= customcmap, s=80, alpha=0.5)

plt.scatter(centroids.iloc[:, 0], centroids.iloc[:, 1],
            marker= 's', s=200, c=[0, 1, 2],
            cmap= customcmap)

ax.set_xlabel('x', fontsize=14)
ax.set_ylabel('y', fontsize=14)
plt.xticks(fontsize=12)
plt.yticks(fontsize=12)
plt.show()
```

✓ 0.1s

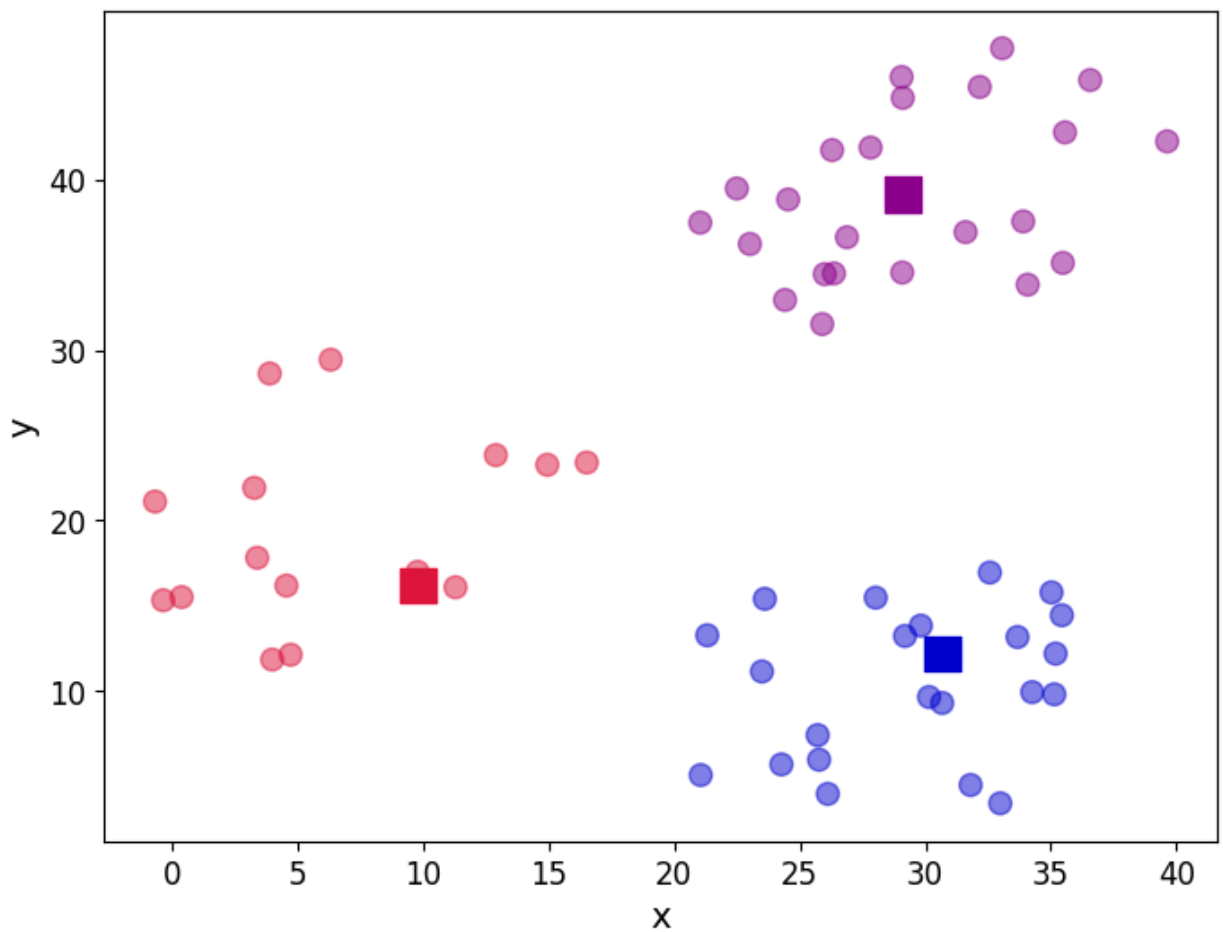

- Tạo hàm tự động lặp lại các bước trên:

```python
def kmeadians(dset, k=2, tol=1e-4):
    working_dset = dset.copy()

    err = []
    goahead = True
    j = 0

    centroids = random_centroids(k , dset)

    while(goahead):
        working_dset['centroid'], j_err = centroid_assignation(working_dset, centroids)
        err.append(sum(j_err))

        centroids = working_dset.groupby('centroid').agg('median').reset_index(drop = True)

        if j > 0:
            if err[j - 1] - err[j] <= tol:
                goahead = False
        j += 1

    working_dset['centroid'], j_err = centroid_assignation(working_dset, centroids)
    centroids = working_dset.groupby('centroid').agg('median').reset_index(drop = True)
    return working_dset['centroid'], j_err, centroids
```

✓ 0.0s

- Khởi tạo và chạy thuật toán K-medians:

```python
np.random.seed(42)
df['centroid'], df['error'], centroids = kmeadians(df[['x', 'y']], 3)
df.head()
```

✓ 0.2s

	ID	x	y	cluster	centroid	error
0	0	24.412	32.932	2	2	9.2470
1	1	35.190	12.189	1	1	6.8565
2	2	26.288	41.718	2	2	6.9510
3	3	0.376	15.506	0	0	6.4780
4	4	26.116	3.963	1	1	10.4435

- Sau khi chạy xong, xem các điểm trung tâm:

```python
centroids
```

✓ 0.0s

	x	y
0	4.550	17.8100
1	29.986	10.5365
2	29.056	37.5350

- Plot đồ thị ra và xem:

```
fig, ax = plt.subplots(figsize=(8, 6))
plt.scatter(x=df['x'], y=df['y'],
            c=df['cluster'].astype('category'),
            cmap= customcmap, s=80, alpha=0.5)

plt.scatter(centroids.iloc[:, 0], centroids.iloc[:, 1],
            marker= 's', s=200, c=[0, 1, 2],
            cmap= customcmap)

ax.set_xlabel('x', fontsize=14)
ax.set_ylabel('y', fontsize=14)
plt.xticks(fontsize=12)
plt.yticks(fontsize=12)
plt.show()
```

✓ 0.0s

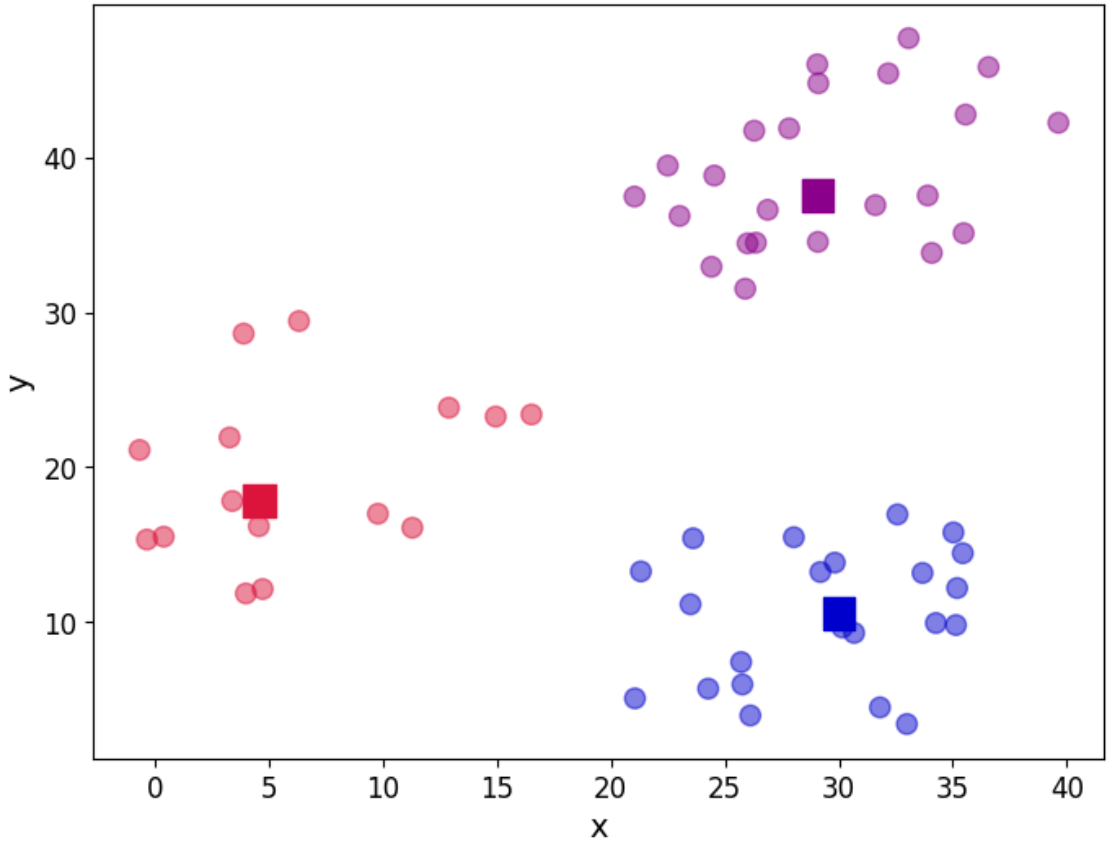

- Vẽ đồ thị để xem sự thay đổ của tổng các error qua từng cluster:

```
err_total = []
n = 10
df_elbow = df[['x', 'y']]
for i in range(n):
    _, my_errs, _ = kmeadians(df_elbow, i + 1)
    err_total.append(sum(my_errs))

fig, ax = plt.subplots(figsize=(8, 6))
plt.plot(range(1, n+1), err_total, linewidth=3, marker='o')

ax.set_xlabel(r'Number of clusters', fontsize=14)
ax.set_ylabel(r'Total error', fontsize=14)
plt.xticks(fontsize=12)
plt.yticks(fontsize=12)
plt.show()
```
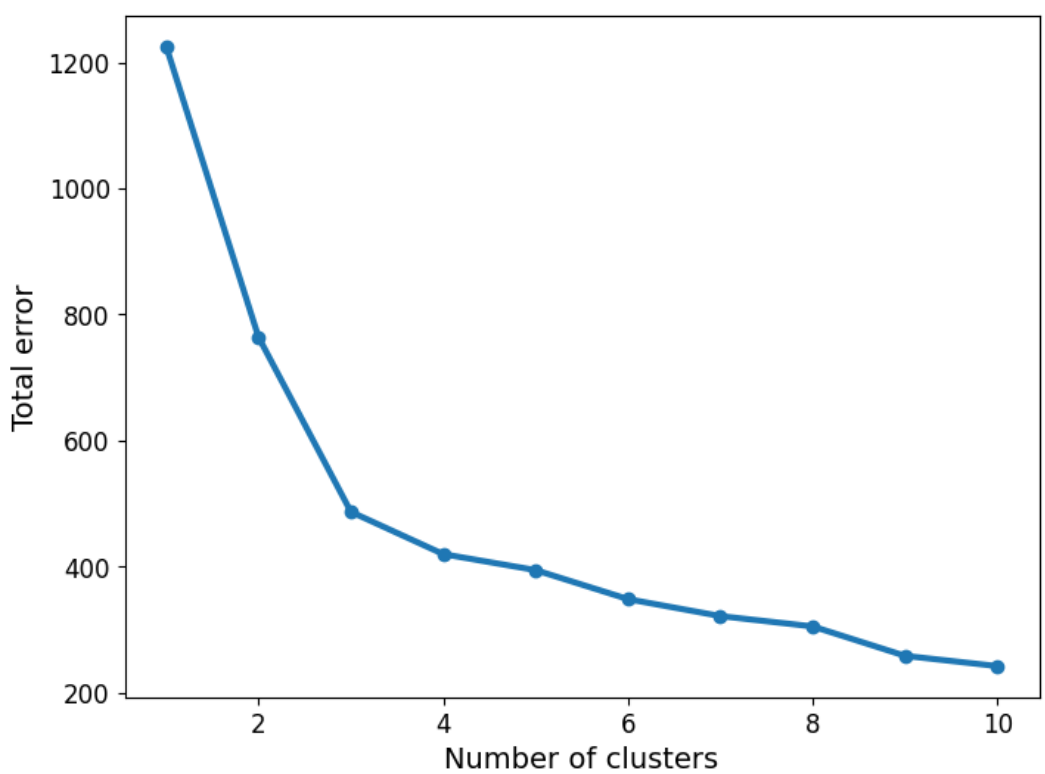
✓ 5.7s